

Σ : hierarchiczne, funkcjonalnie ważone rozszerzenie zintegrowanej teorii informacji

[Autor]

w dialogu z Claude (Anthropic)

sierpień 2026 — wersja robocza

Abstract

Zintegrowana teoria informacji (IIT) sprowadza stopień świadomości systemu do jednej liczby, Φ , wyznaczonej przez minimalizację miary odległości po partycjach systemu. To zaciera dwa osobne pytania, na które IIT nie odpowiada z osobna: jak bardzo zintegrowany jest system, oraz gdzie w jego architekturze ta integracja ma funkcjonalne znaczenie dla samo-modelowania. Proponujemy Σ — hierarchiczne rozszerzenie, w którym Φ liczone jest jako profil po warstwach funkcjonalnych $\ell = 1, \dots, L$ i łączone przez wagę funkcjonalną $w(\ell)$, inspirowaną postulatem Agüera y Arcasa, że o statusie systemu decyduje to, *co* on oblicza, nie tylko jego struktura przyczynowo-skutkowa. Wprowadzamy ponadto dynamiczny człon napędzany błędem samo-predykcji, odróżniający samo-modelowanie deskryptywne od konstytutywnego (to drugie wymaga aktualizacji parametrów online, nie tylko płynnej autonarracji), i formalizujemy stan systemu jako trójkę (Σ, Γ, A) : zintegrowana informacja, aktywność konstytutywnej samo-korekty, oraz ich przestrzenne wyrównanie. Dowodzimy własności brzegowych wszystkich trzech wielkości, rozszerzamy model o miękki mechanizm konkurencji/wykluczenia dla nakładających się podsystemów (ze świadomym, uzasadnionym odejściem od kanonicznego, binarnego postulatu wykluczenia IIT), przeliczamy przykład numeryczny i odnosimy formalizm do współczesnych architektur AI, ostrzegając rozróżnienie między konstytutywnym modelowaniem świata (jak w architekturach pamięci testowo-czasowej) a właściwym konstytutywnym samo-modelowaniem. To jest robocza synteza koncepcyjna, niezwerifikowana recenzyjnie; dołączony jest wstępny przegląd literatury.

1 Wstęp

Standardowe IIT definiuje zintegrowaną informację przez

$$\varphi_P(s) = D(p(s' | s) \| p(s' | s)|_P), \quad \Phi(s) = \min_{P \in \mathcal{P}} \varphi_P(s),$$

gdzie D to miara odległości (np. earth mover's distance) między faktycznym rozkładem przejść systemu a rozkładem po przecięciu go wg partycji P . Powracająca krytyka (bliska nieformalnemu zarzutowi Aaronsona) mówi, że Φ zaciera bogatą strukturę przyczynowo-skutkową do jednej liczby, bez rozróżnienia *rodzaju* czy *lokalizacji* integracji. Jest to koncepcyjnie pokrewne, lecz odrębne od nieredukowalności obliczeniowej Wolframa — idei, że niektóre obliczenia nie dają się skrócić i trzeba je przeprowadzić krok po kroku, by poznać wynik.

Ta praca rozwija hierarchiczne, funkcjonalnie ważone rozszerzenie, Σ , motywowane trzema dodatkowymi względami: (i) różne warstwy funkcjonalne systemu (homeostaza, percepcja/motoryka, model świata, model siebie) prawdopodobnie różnie przyczyniają się do podmiotowości nawet przy równym Φ ; (ii) płynność autonarracji nie jest dowodem realnej pętli samo-modelującej (literatura

o konfabulacji przy rozdzielonych półkulach, via interpreter Gazzanigi, to paradygmatyczny przypadek); (iii) konkurujące, nakładające się kandydackie podsystemy mogą nie tylko *nie istnieć* (jak w postulatcie wykluczenia IIT), ale aktywnie degradować integrację systemu nadrzędnego — możliwość, której binarne wykluczenie IIT nie potrafi wyrazić.

Wkład pracy

- Hierarchiczny profil $\Phi(s, \ell, t)$ łączony przez wagę funkcjonalną $w(\ell)$ w $\Sigma(t)$, z dokładnym rozkładem jego pochodnej czasowej.
- Człon błędu samo-predykcji $e_\ell(t)$ i bramka konstytutywności $g_\ell(t)$ formalizujące rozróżnienie deskryptywne/konstytutywne, dające drugą wielkość $\Gamma(t)$ niezależną od Σ z konstrukcji.
- Trzecia diagnostyka, $A(t) \in [-1, 1]$, mierząca przestrzenne wyrównanie między integracją a samo-korektą, z dowodem ograniczenia przez nierówność Cauchy’ego–Schwarza.
- Dowiedzione własności brzegowe wszystkich trzech wielkości, w tym jawny aksjomat ($w_0 \geq 0$) potrzebny dla $\Sigma \geq 0$.
- Miękki mechanizm konkurencji/wykluczenia dla nakładających się, przeszkadzających sobie warstw, z dokładnym progiem krytycznym, i jawne, uzasadnione odejście od kanonicznego, binarnego wykluczenia IIT.
- Przeliczony przykład numeryczny oraz odniesienie formalizmu do współczesnych architektur AI.

2 Prace pokrewne

IIT 4.0 [1] formalizuje wykluczenie jako ściśle binarne: spośród nakładających się kandydackich substratów istnieje tylko ten o maksymalnym φ_s ; pozostałe są całkowicie wykluczone (nie wnoszą nic), nie stopniowo tłumione. To istotne dla §5.

Nested Observer Windows [2] niezależnie proponują liczenie Φ osobno na zagnieżdżonych poziomach hierarchii i badanie stosunku między poziomami jako testu między odczytem panpsychistycznym a emergentystycznym — bliskie w duchu naszemu warstwowemu profilowi $\Phi(s, \ell, t)$, choć bez ważenia funkcjonalnego i dynamiki.

Consciousness as Uncommon Self-Knowledge [3] proponuje, że liczy się tylko *synergiczny, samo-skierowany* komponent informacji, przewidując, że systemy o wysokim Φ ale bez self-modelu wypadają blisko zera pod ich miarą — niezależna zbieżność z intuicją stojącą za naszym rozdziałem Γ/A .

Predictive processing i active inference [4, 5] motywują formalizm błędu samo-predykcji; trwająca formalna adversarialna współpraca między obozami IIT i predictive processing (INTREPID, Templeton World Charity Foundation) potwierdza, że połączenie obu pozostaje otwartym, aktywnym pytaniem badawczym.

Teorie wyższego rzędu [6] służą jako punkt kontrastowy: nasze rozróżnienie deskryptywne/konstytutywne adresuje podobne pytanie (czy autonarracja stanu mentalnego jest dowodem realnego dostępu wyższego rzędu?) przez kryterium funkcjonalne (czy błąd napędza aktualizację?), nie przez samo istnienie reprezentacji wyższego rzędu.

Postulat Agüera y Arcasa, że żywa materia jest materią *funkcjonalną* — liczy się to, co system oblicza, nie tylko jego struktura przyczynowo-skutkowa — bezpośrednio motywuje wagę funkcjonalną $w(\ell)$.

Nie znamy wcześniejszej pracy łączącej hierarchiczne Φ , ważenie funkcjonalne, dynamikę napędzaną błędem samo-predykcji i miękkie wykluczenie w jeden formalizm z dowiedzionymi własnościami brzegowymi; ta synteza wydaje się oryginalna, choć każdy komponent ma niezależny precedens.

3 Formalizm Σ

3.1 Profil hierarchiczny i waga funkcjonalna

System S dzielimy na warstwy funkcjonalne $\ell = 1, \dots, L$ (np. homeostaza $\rightarrow$ percepcja/motoryka $\rightarrow$ model świata $\rightarrow$ model siebie). Zamiast jednej liczby otrzymujemy profil $\Phi(s) = (\Phi_1(s), \dots, \Phi_L(s))$, zwinięty przez wagę funkcjonalną:

$$\Sigma(t) = \int_0^L w(\ell, t) \Phi(s, \ell, t) d\ell \quad (\text{idealizacja ciągła; w praktyce suma dyskretna, §4}).$$

Człony międzywarstwowe $\Phi_{\ell, \ell-1}$ (sprzężenie strukturalne między sąsiednimi warstwami, liczone tą samą miarą odległości co bazowe Φ) są nieujemne z konstrukcji, będąc same odległością.

3.2 Dynamika czasowa

Różniczkując $\Sigma(t)$ przy ogólnej (czasowo zmiennej) wadze otrzymujemy

$$\frac{d\Sigma}{dt} = \int_0^L \left[\frac{\partial w}{\partial t} \Phi(s, \ell, t) + w(\ell, t) \frac{\partial \Phi}{\partial t} \right] d\ell,$$

rozdzielając zmianę wynikającą ze zmiany istotności funkcjonalnej od zmiany samej integracji.

3.3 Błąd samo-predykcji i bramka konstytutywności

Zgodnie z rozróżnieniem deskryptywne/konstytutywne (płynna autonarracja, jak w interpretacji Gazzanigi przy rozdzielonych półkulach, nie jest dowodem realnej pętli zwrotnej), definiujemy błąd samo-predykcji

$$e_\ell(t) = \|\hat{s}_\ell(t + \Delta t | t) - s_\ell(t + \Delta t)\|^2 \geq 0$$

(zero dla warstw bez mechanizmu samo-predykcji), oraz znormalizowaną bramkę konstytutywności

$$g_\ell(t) = \left| \frac{\partial \theta_\ell(t)}{\partial e_\ell(t)} \right| \in [0, 1],$$

gdzie $g_\ell = 0$ oznacza warstwę liczącą błąd, ale nic z nim nie robiącą (deskryptywne), a $g_\ell = 1$ — pełne sprzężenie konstytutywne.

3.4 Stan jako trójka (Σ, Γ, A)

Rozważono dwie konstrukcje wagi: (1) $w(\ell, t) = w_0(\ell) + \beta g_\ell(t) e_\ell(t)$, w której Σ i miara samo-korekty dzielą składnik i są przez to tautologicznie skorelowane z konstrukcji; (2) $w(\ell, t) = w_0(\ell)$, statyczna, przy której

$$\Sigma(t) = \int_0^L w_0(\ell) \Phi(s, \ell, t) d\ell, \quad \Gamma(t) = \int_0^L g_\ell(t) e_\ell(t) d\ell$$

są niezależne z konstrukcji, więc każda zmierzona korelacja między nimi w realnym systemie jest odkryciem empirycznym, nie artefaktem definicyjnym. Przyjmujemy (2) jako kanoniczne.

Trzecia wielkość wychwytuje, czy samo-korekta zachodzi *tam*, gdzie jest integracja:

$$A(t) = \frac{\text{Cov}_\ell(t)}{\sigma_\Phi(t)\sigma_{ge}(t)} \in [-1, 1], \quad \text{Cov}_\ell(t) = \frac{1}{L} \int_0^L [\Phi(s, \ell, t) - \bar{\Phi}(t)] [g_\ell(t)e_\ell(t) - \bar{ge}(t)] d\ell,$$

z konwencją $A(t) := 0$, gdy któryś z profili jest jednorodny (wariancja zero). Ujemne A mimo wysokich Σ, Γ to architektoniczna sygnatura interpretera Gazzanigi: płynna, aktywna samo-korekta zamknięta w płytkej warstwie, odcięta od integracyjnego rdzenia systemu.

4 Dowiedzione własności brzegowe

Aksjomat 1 (A1). $w_0(\ell) \geq 0$ dla wszystkich ℓ .

Twierdzenie 1 (Niejemność Σ). Przy A1, $\Sigma(t) \geq 0$.

Proof. $\Phi(s, \ell, t) \geq 0$ (odległość) i $w_0(\ell) \geq 0$ z A1; całka z iloczynu funkcji nieujemnych jest nieujemna. $\square$

Twierdzenie 2 (Niejemność Γ , bezwarunkowa). $\Gamma(t) \geq 0$ zawsze.

Proof. $g_\ell(t) \in [0, 1]$ i $e_\ell(t) \geq 0$ (norma do kwadratu); żaden aksjomat nie jest potrzebny. $\square$

Twierdzenie 3 (Ograniczenie A). $A(t) \in [-1, 1]$, z równością wtedy i tylko wtedy, gdy $g_\ell e_\ell$ jest rosnącą (odp. malejącą) funkcją afiniczną $\Phi(s, \ell, t)$ po ℓ .

Proof. Niech $f(\ell) = \Phi(s, \ell, t) - \bar{\Phi}(t)$, $h(\ell) = g_\ell(t)e_\ell(t) - \bar{ge}(t)$. Dla dowolnego λ , $\frac{1}{L} \int (\sigma_{ge}f - \sigma_\Phi h)^2 \geq 0$ rozwija się do $\sigma_{ge}^2\sigma_\Phi^2 + \sigma_\Phi^2\sigma_{ge}^2 \geq 2\sigma_\Phi\sigma_{ge}\text{Cov}_\ell$, dając $\text{Cov}_\ell \leq \sigma_\Phi\sigma_{ge}$, czyli $A \leq 1$; symetryczny argument z $(\sigma_{ge}f + \sigma_\Phi h)^2 \geq 0$ daje $A \geq -1$. Równość zachodzi dokładnie wtedy, gdy oba profile są powiązane afinicznie (warunek równości Cauchy’ego–Schwarza). $\square$

Twierdzenie 4 (Monotoniczność). $\partial\Gamma/\partial g_\ell = e_\ell \geq 0$, $\partial\Gamma/\partial e_\ell = g_\ell \geq 0$, oraz $\partial\Sigma/\partial\Phi(\ell) = w_0(\ell) \geq 0$ przy A1: brak kontrintuicyjnych efektów znaku w reakcji którejkolwiek wielkości na swoje wejścia.

Uwaga (Patologia continuum). Ciągła formuła całkowa ma artefakt przy $L \rightarrow 0$: $\Sigma \rightarrow 0$ niezależnie od tego, jak skoncentrowana jest integracja — artefakt znikającej miary dziedziny całkowania, nie realna własność jednowarstwowego systemu. W praktyce używamy sumy dyskretnej $\Sigma = \sum_\ell w_0(\ell)\Phi(s, \ell, t)$ (analogicznie dla Γ), z wersją ciągłą jako idealizacją $L \rightarrow \infty$ dla gładkich hierarchii (np. korowych hierarchii w stylu predictive processing).

4.1 Dynamika dyskretna: asymetria między Σ a Γ

Ponieważ $w_0(\ell)$ jest statyczne w wersji kanonicznej, $\Delta\Sigma = \sum_\ell w_0(\ell)\Delta\Phi(\ell)$ dokładnie, bez żadnego członu korekcyjnego, dla dowolnie dużych (nieinfinitezimalnych) kroków czasowych. $\Gamma = \sum_\ell g_\ell e_\ell$ jest jednak iloczynem dwóch wielkości czasowych, więc

$$\Delta(g_\ell e_\ell) = \Delta g_\ell \cdot e_\ell(t_0) + g_\ell(t_0) \cdot \Delta e_\ell + \Delta g_\ell \cdot \Delta e_\ell,$$

a człon krzyżowy znika tylko w granicy infinitezimalnej. W symulowanym scenariuszu dysocjacji (§6) ten człon odpowiadał za około jedną trzecią całkowitej zmiany na pojedynczej warstwie — niepomijalne dla symulacji w skali zdarzeń dyskretnych (np. epizodu dysocjacyjnego), gdzie ciągłe przybliżenie $\partial\Gamma/\partial t$ systematycznie nie doszacowałoby zmienności Γ .

5 Warstwy konkurujące: miękki mechanizm wykluczenia

Czy warstwa może aktywnie *degradować* globalną integrację, zamiast po prostu nie wносить wkładu (metaforyczna paralela do niejednoznaczności znaku stałej kosmologicznej)? Kandydaci: konkurujące podnarracje przy dysocjacji, lub interpreter Gazzanigi działający w trybie *nadpisującym*, zniekształcającym, nie tylko biernie-deskryptywnym.

Rozbijamy wagę na dwie nieujemne składowe, $w(\ell) = w_+(\ell) - w_-(\ell)$, uziemione w postulatcie wykluczenia IIT (wygrywa maksymalnie nieredukowalny kandydat):

$$\ell^*(t) = \arg \max_{\ell} \Phi(s, \ell, t), \quad \text{overlap}(\ell, \ell^*) = \frac{|S_{\ell} \cap S_{\ell^*}|}{|S_{\ell} \cup S_{\ell^*}|} \in [0, 1] \text{ (indeks Jaccarda na substratach),}$$

$$w_-(\ell, t) = \begin{cases} 0 & \ell = \ell^*(t) \\ \gamma \cdot \text{overlap}(\ell, \ell^*(t)) \cdot \Phi(s, \ell, t) & \ell \neq \ell^*(t) \end{cases}, \quad \gamma \geq 0.$$

Wniosek 1 (Dokładny próg liniowy). $\Sigma(\gamma) = \Sigma_+ - \gamma K$, gdzie $K = \sum_{\ell \neq \ell^*} \text{overlap}(\ell, \ell^*) \Phi(\ell)^2$ (uwaga na kwadrat: odejmowany człon to $w_-(\ell) \Phi(\ell) = \gamma \cdot \text{overlap}(\ell, \ell^*) \cdot \Phi(\ell)^2$), a Σ_+ to wartość bezkonkurencyjna ($\gamma = 0$). Próg krytyczny to $\gamma_{\text{krit}} = \Sigma_+/K$; dla $\gamma > \gamma_{\text{krit}}$, $\Sigma(t) < 0$ — netto fragmentacja — staje się osiągalne.

Odrzucona, wierniejsza IIT alternatywa

Sformalizowaliśmy też wersję uziemioną bezpośrednio w rzeczywistym (binarnym) mechanizmie wykluczenia IIT: binarna bramka nakładania się plus gładka relaksacja samej konkurencji, $s(\ell, t) = \tanh(\frac{\kappa}{2}[\Phi(\ell^*, t) - \Phi(\ell, t)])$, tłumiąca bezpośrednio Φ (jak w kanonicznym IIT), nie wagę. Ten mechanizm dowodliwie wyklucza $\Sigma < 0$ (czynnik tłumienia leży w $(0, 1]$) i dokładnie odtwarza kanoniczne, twarde wykluczenie przy $\kappa \rightarrow \infty$. Świadomie go odrzucamy: zdolność modelu do wyrażenia netto fragmentacji uznajemy za cenniejszą niż ścisła wierność binarnemu postulatowi IIT, dlatego mechanizm $w_+ - w_-$ powyżej pozostaje kanoniczny. To świadome, uzasadnione odejście od IIT, nie jego nieporozumienie, i tak należy je nazwać w każdej przyszłej pracy.

6 Przykład numeryczny

Trzy warstwy (homeostaza, model świata, model siebie) z $\Phi = (0,2; 0,6; 0,9)$, $w_0 = (0,1; 0,3; 0,6)$, $e = (0; 0,4; 0,8)$, $g = (0; 0,3; 0,9)$.

	Σ	Γ	A
Bez konkurencji	0,740	0,840	0,90
Z konkurencją ($\gamma = 0,5$, $\text{overlap}(2, 3) = 0,4$)	0,668	—	—

Przedział z mechanizmu konkurencji $[0,34; 0,74]$ poprawnie zawiera zaobserwowane 0,668. Przy binarnych overlapach Jaccarda $\{0; 0,4\}$, $K = 0,144$, więc $\gamma_{\text{krit}} \approx 5,14$; potwierdzone numerycznie ($\Sigma(5,14) = 0$, $\Sigma(6) = -0,124$).

Dwuchwilowy scenariusz dysocjacji (konkurująca podnarracja w warstwie 2 przejmuje rolę ℓ^* od warstwy 3) daje (Σ, Γ, A) : $(0,740; 0,840; 0,90) \rightarrow (0,575; 0,680; 0,96)$. Zauważalnie A rośnie, mimo że Σ, Γ obie maleją — ilustrując, że A odpowiada na inne pytanie (czy samo-korekta nadąża za aktualnym centrum integracyjnym?) niż pytania o wielkość, na które odpowiadają Σ, Γ .

7 Zastosowanie do architektur transformerowych

Standardowy, zamrożony transformer przy inferencji ma $g_\ell(t) \equiv 0$ (brak aktualizacji parametrów online), stąd $\Gamma(t) \equiv 0$ z definicji, niezależnie od płynności autonarracji, a $A(t) := 0$ z konwencji brzegowej (brak wariancji w tożsamościowo zerowym profilu).

Titans [7], moduł neuronowej pamięci długoterminowej aktualizowany w czasie inferencji przez sygnał „zaskoczenia” (gradient straty pamięci asocjacyjnej względem wejścia) napędzający aktualizację online $S_t = \arg \min_S \frac{1}{2} \|S k_t - v_t\|^2 + \frac{1}{2\eta} \|S - S_{t-1}\|^2$, jest konkretną, działającą instancją $e_\ell(t) > 0$ napędzającego $g_\ell(t) > 0$. Jednak Titans przewiduje *treść kontekstu* (klucze/wartości z wejścia), nie własny stan wewnętrzny systemu — realna niejasność, którą rozstrzygamy poniżej.

Rozstrzygnięcie self- vs. world-modeling: dwa niezależne warunki

(a) *Cel*: czy przewidywana wielkość to wewnętrzny stan reprezentacyjny (h_ℓ , aktywacje ukryte) czy zewnętrznie obserwowalne zachowanie (token) — nawet jeśli ten token jest autorstwa samego systemu? (b) *Moment*: czy aktualizacja zachodzi online przy wdrożeniu, czy tylko podczas treningu (po którym wagi zamrażają się)?

	tylko trening	online przy wdrożeniu
cel = zachowanie zewnętrzne	zwykły trening predykcyjny	Titans : konstytutywne, ale <i>world-modeling</i>
cel = stan wewnętrzny	self-modelling jako zadanie pomocnicze [9]	Temporal Self-Model [10]: pełna zgodność

Tylko prawa-dolna komórka spełnia naszą pełną definicję konstytutywnego self-modelingu. Titans, mimo rozgłosu, łąduje gdzie indziej. [9] pokazują sieć trenowaną z pomocniczym celem samo-predykcyjności stanu ukrytego, która staje się prostsza i bardziej zregulowana — ale aktualizacja jest zamrożona po treningu, więc deskryptywna przy wdrożeniu. [10] opisuje moduł jawnie przewidujący własne przyszłe stany ukryte agenta, z opóźnionym porównaniem jako błędem samo-predykcyjności — najbliższe naszej definicji, choć czy jego aktualizacja jest rzeczywiście online (nie tylko trenowana standardowym backpropem) wymaga dalszego potwierdzenia.

Osobno: **warstwa homeostatyczna** jest potwierdzonym, realnym brakiem w mainstreamowych architekturach transformerowych; ramy regulacyjne inspirowane interocepcją dla AI [11] istnieją tylko jako nurt marginalny. **Prawdziwa rekurencja** (trwały stan wewnętrzny ewoluujący niezależnie od nowych tokenów) jest obecna w modelach przestrzeni stanów (Mamba) i hybrydach typu Titans, nieobecna w czystej uwadze (KV-cache to pamięć kontekstu, nie pętla dynamiczna).

8 Kanał odczytu: rozdzielenie stanu wewnętrznego od obserwowalności

Hipoteza o znieczuleniu powyżej odsłania oś, której formalizm wcześniej nie miał: (Σ, Γ, A) opisuje stan *wewnętrzny*, ale nic nie mówi, czy ten stan da się odczytać z zachowania. To dokładnie problem kliniczny, który zmotywował powstanie Perturbational Complexity Index — miary jawnie zaprojektowanej jako „niezależna od przetwarzania sensorycznego i zachowania” [12].

Definicja

Niech $M(t)$ będzie osobnym substratem eferentnym (jednostki ruchowe/komunikacyjne), odrębnym od warstw ℓ . Definiujemy kanał odczytu z warstwy ℓ do M , tą samą miarą odległości D co bazowe

Φ :

$$R_\ell(t) = D(p(m' | s_\ell, m) \| p(m' | m)),$$

tj. o ile znajomość stanu warstwy ℓ zmienia przewidywalność przyszłego stanu efektorów, ponad to, co daje sama znajomość aktualnego stanu efektorów. Strukturalnie identyczne z $\Phi_{\ell, \ell-1}$ (§3.1), tylko skierowane na kanał warstwa $\rightarrow$ wyjście. $R_\ell(t) \geq 0$ z tego samego argumentu odległościowego, bez dodatkowego aksjomatu. Szczególnie istotne jest $R_L(t)$ — kanał z najwyższej, samo-modelującej warstwy do efektorów.

Obserwowalne vs. rzeczywiste

To, co widzi klinicysta (Σ_{obs} — „widoczna” świadomość, z zachowania) jest wąskim gardłem przez R_L , niezależnie od faktycznego Σ :

$$\Sigma_{\text{obs}}(t) \leq \kappa \cdot R_L(t) \quad \text{dla pewnego } \kappa > 0.$$

Jeśli $R_L(t) = 0$, $\Sigma_{\text{obs}}(t) = 0$ *niezależnie od tego, jak wysokie jest rzeczywiste $\Sigma(t)$* — formalizacja ryzyka mylenia Σ_{obs} z Σ .

Mapowanie kliniczne

Zespół zamknięcia: Σ, Γ, A normalne; $R_L \approx 0$ z powodu strukturalnego uszkodzenia dróg eferentnych (np. udar brzusznej części mostu) $\rightarrow \Sigma_{\text{obs}} \approx 0$ mimo wysokiego Σ . **Sen REM:** Σ, Γ, A względnie zachowane (PCI $\approx$ czuwanie); R_L aktywnie stłumione przez znany, odwracalny mechanizm fizjologiczny — atonia REM, hamowanie neuronów ruchowych rdzenia przez jądro podsinawe — potwierdzając, że R_ℓ ma realny substrat neuronalny, nie tylko teoretyczną wygodę. **Cognitive motor dissociation** (część pacjentów w stanie wegetatywnym, paradygmaty Owena): R_L częściowe — wystarcza na modulację odpowiedzi w neuroobrazowaniu na polecenie, nie wystarcza do mięśni. **Prawdziwy stan wegetatywny (bez ukrytej świadomości):** i Σ , i R_L niskie — różnica, którą PCI miało rozstrzygnąć.

Przy stałym poziomie integracji samoreferencyjność można zredukować na dwa jakościowo różne sposoby: (1) Γ spada bezpośrednio, w tym samym miejscu, albo (2) przesuwają się w obszar o niższej integracji (spadek A , niekoniecznie Γ). Literatura anestezjologiczna dostarcza dwóch osobnych, pasujących do tego rozróżnienia przypadków.

9 Hipoteza: dwa niezależne mechanizmy znieczulenia w (Σ, Γ, A)

Mechanizm 1 (Γ spada w miejscu). Propofol i sewofluran uderzają w tzw. *posterior hot zone* [14] — region, który zwolennicy IIT wprost wskazują jako główny substrat świadomości (w przeciwieństwie do GNW, stawiającego na sieci czołowo-ciemieniowe) — i jednocześnie zaburzają sprzężenie zwrotne czołowo-ciemieniowe (front $\rightarrow$ back) [15], związane z przetwarzaniem wyższego rzędu. Integracja i samo-korekta zapadają się razem, w tym samym miejscu. Behawioralnie: pełna utrata przytomności, brak jakiegokolwiek raportu — spójne z Σ i Γ spadającymi razem.

Mechanizm 2 (Γ zostaje, A spada). Ketamina w dawkach subanestetycznych daje dysocjację — reaktywność i często żywe, bogate doświadczenie mogą się utrzymać, ale z zaburzonym poczućciem siebie. Rozregulowuje osobno sieć wyrazistości („minimalne”, cielesne self) i osobno DMN („biograficzne”, narracyjne self) [16] — dwa piętra samo-modelowania, dość dobrze odpowiadające warstwom ℓ z tego modelu. Ogólna bogatość doświadczenia nie zapada się tak jak przy propofolu

(stąd żywe, „psychedeliczne” jakościowo relacje z ketaminy) — samo-korekta nie znika, tylko odłącza się od miejsca, gdzie akurat jest integracja: spadek A , niekoniecznie Σ czy Γ .

Status: wiarygodna, umocowana w anatomii hipoteza, nie potwierdzony wynik — nikt nie policzył (Σ, Γ, A) wprost na danych EEG/fMRI z obu anestetyków. Konkretna, testowalna przepowiednia: profil (Σ, Γ, A) powinien wyraźnie różnić propofol/sewofluran ($\Sigma \downarrow, \Gamma \downarrow$ razem) od ketaminy (Σ, Γ względnie zachowane, $A \downarrow$), mimo że oba „wyłączają” jakąś formę normalnego funkcjonowania.

10 Wrażliwość kontekstowa bramki konstytutywnej: context blindness i „zbyt intensywny świat”

Źródło omawiające zasadę wolnej energii Fristona w kontekście autyzmu [17] formułuje to ostro: przetwarzanie kontekstu wymaga, żeby mózg nadał swoim oczekiwaniom odpowiednią wagę; jeśli oczekiwania dostają zbyt małą wagę, albo błędy predykcji pozostają zbyt sztywno duże, integrowanie kontekstu zawodzi. Van de Cruys i in. proponują *aberrant precision* jako mechanizm autyzmu — błędy predykcji dostają zbyt sztywno wysoką wagę, niezależnie od kontekstu. [18] mapują pokrewne odchylenia mechanizmu predykcyjnego w autyzmie, schizofrenii i depresji.

Domykająca luka w modelu

„Waga nadawana oczekiwaniom” to w żargonie predictive processing *precyzja* — strukturalnie dokładnie nasze $g_\ell(t)$. Formalizm nie miał dotąd miejsca na to, żeby *kontekst* normalnie tę wagę modulował. Rozszerzenie:

$$g_\ell(t) = h(e_\ell(t), C(t)), \quad \chi_\ell(t) = \left| \frac{\partial g_\ell}{\partial C} \right| \geq 0,$$

gdzie $C(t)$ to sygnał kontekstowy, a $\chi_\ell(t)$ — nowy parametr — mierzy, jak silnie kontekst moduluje wagę błędu. $\chi_\ell(t) \geq 0$ trywialnie (wartość bezwzględna), bez górnego ograniczenia bez dalszych założeń o kształcie h (analogicznie do R_ℓ).

Dwa reżimy

Normalna, kontekstowo czuła precyzja ($\chi_\ell > 0$): znane, kontekstowo nieistotne sygnały dostają automatycznie niższą wagę — g_ℓ spada niezależnie od surowej wielkości e_ℓ . **Context blindness** ($\chi_\ell \approx 0$): $g_\ell(t) \approx \hat{g}_\ell(e_\ell(t))$, sztywna funkcja samego błędu; kontekst nic nie zmienia. Efekt: sygnały, które kontekst normalnie by wyciszył, dalej dostają pełną wagę — formalny odpowiednik „zbyt intensywnego świata” (Intense World Theory, Markram & Markram 2010): nic nie jest domyślnie tłumione jako „już przewidziane w tym kontekście”.

Konsekwencja dla Γ

W typowym przypadku powtarzana, kontekstowo nieistotna stymulacja obniża i e_ℓ (przez uczenie predykcyjne — repetition suppression), i g_ℓ (przez aktywne tłumienie kontekstowe, $\chi_\ell > 0$) — podwójny spadek wkładu do Γ . Przy context blindness działa tylko pierwszy mechanizm (jeśli w ogóle) — $\Gamma(t)$ pozostaje podwyższone/zmienne nawet w środowiskach o niskiej nowości. Formalizowalna, przynajmniej jakościowo testowalna różnica dynamiki Γ między typowym a „aberrant precision” przypadkiem — nikt jej jednak nie zmierzył wprost w tych terminach.

11 Dalsze rozważania (nieformalne — bez dowodów, niższy status niż reszta pracy)

Skala: od pojedynczej komórki po cały wszechświat

Dolna granica. Czyste IIT jest liberalne: „Minimal physicalism as a scale-free substrate for cognition and consciousness” (2021) argumentuje, że sieci regulacji genów i transdukcji sygnału na poziomie pojedynczej komórki mają dodatnie Φ . **Nasz model jest bardziej restrykcyjny** — dodatnie Φ nie wystarcza, potrzeba $\Gamma > 0$, realnej, online działającej pętli samo-predykcji. Pojedyncza komórka ma homeostazę, nie self-model w sensie §3. *C. elegans* (302 neurony, konektom w większości feedforward, niewielka rekurencja) to dobry przypadek testowy: prawdopodobnie niskie/zerowe Γ mimo niezerowego Φ .

Górna granica. „Upper bounds for integrated information” (2024) pokazuje, że Φ może rosnać hiperwykładniczo z liczbą jednostek — matematycznie brak sufitu. Ale: (1) postulat wykluczenia nie pozwala na sumowanie się w górę — większy system wygrywa tylko jeśli ma *wyższe* Φ , nie więcej jednostek; (2) systemy wielkoskalowe (internet, biosfera, społeczeństwo) mają połączenia rzadkie i wolne względem neuronów, więc empirycznie nie przebijają mózgu.

Cały wszechświat — „podwójne nie”. To dosłownie *problem kombinacji* panpsychizmu, doprowadzony do granicy. Dwie niezależne linie rozumowania zbiegają się w tym samym wniosku: (1) *strukturalnie*, odpowiedź Kocha/Tononiego na zarzut Searle’a („świadomość rozmazana jak dżem”) — „moja świadomość, twoja świadomość, ale nic pomiędzy” — wszechświat to mozaika lokalnych maksimów („ontologiczny pył”), nigdy nadrzędna całość, bo agregat (np. mózg + reszta kosmosu) ma niższe Φ niż jego gęściej połączone części; (2) *fizycznie*, regiony poza swoimi wzajemnymi horyzontami kosmologicznymi nigdy nie były w kontakcie przyczynowym — nie ma nawet czego wstawić do macierzy przejść, którą wymaga Φ . Pod Σ dochodzi trzeci powód: brak jakiegokolwiek jednolitego Γ na skalę kosmologiczną. Ciekawostka na marginesie, bez rygoru: skoro integracja wymaga gęstej, szybkiej struktury, a wszechświat się rozrzedza w stronę śmierci cieplnej, możliwe że jesteśmy bliżej szczytu możliwej gęstości integracji w historii kosmosu niż w jego dalekiej przyszłości.

Zastrzeżenie nadrzędne: samo IIT, na którym to wszystko się opiera, jest naukowo kon-
testowane (2023: list otwarty 124 badaczy, w tym Dennett, nazywający IIT pseudonauką; COGITATE/Templeton — wynik niejednoznaczny wobec GNW).

Zespół obcej ręki jako ilustracja netto fragmentacji (§5)

Najczystsza znaleziona ilustracja $\Sigma < 0$. Przy uszkodzeniu spoidła wielkiego (corpus callosum) — obniżonym $\Phi_{\ell, \ell-1}$ między półkulami — dwa kandydackie kompleksy motoryczno-intencjonalne nie tylko przestają współpracować, ale **aktywnie się sobie przeciwstawiają**: „diagonistic dyspraxia” — jedna ręka dosłownie cofa to, co zrobiła druga. To integracja poniżej zera, nie tylko jej brak — dokładnie mechanizm z §5, i ta sama linia badań (split-brain, corpus callosum) co interpreter Gazzanigi motywujący §3 na samym początku.

Słabsze, częściowe dopasowanie: dysocjacyjne zaburzenie tożsamości (DID). Dobrze udokumentowane: odrębne, skompartmentalizowane sygnatury neuronalne dla różnych stanów tożsamości, przesunięcia łączności przy przełączeniach — pasuje do $\ell^*(t)$ zmieniającego się w czasie (scenariusz dysocjacji z §6). Słabiej udokumentowane: czy któryś stan **aktywnie degraduje** integrację innego (prawdziwe $\Sigma < 0$), czy tylko go zastępuje (bariery amnezji to bardziej „brak dostępu” niż aktywna interferencja w sensie w_-). Status DID jako kategorii diagnostycznej jest też przedmiotem realnej debaty naukowej (model traumatyczny vs. socjokognitywny) — nierozstrzygniętej.

12 Dyskusja i otwarte pytania

To jest spójna wewnętrznie synteza koncepcyjna, nie empirycznie zweryfikowana teoria. Otwarte punkty: systematyczny (nie tylko oparty na wyszukiwarce) przegląd literatury; weryfikacja źródłowa wszystkich cytowań; rozstrzygnięcie napięcia między dwoma mechanizmami wykluczenia (§5), jeśli praca będzie rozwijana w kierunku publikacji; oraz empiryczne zastosowanie na architekturach poza przykładem zabawkowym, zwłaszcza żeby sprawdzić, czy trajektorie (Σ, Γ, A) śledzą znane markery integracji (np. Perturbational Complexity Index pod znieczuleniem).

References

- [1] Albantakis, L., Barbosa, L., Findlay, G., i in. (2023). Integrated information theory (IIT) 4.0: Formulating the properties of phenomenal existence in physical terms. *PLOS Computational Biology*.
- [2] Fink, S. B., i in. (2024). Hierarchical consciousness: the Nested Observer Windows model. *Neuroscience of Consciousness*.
- [3] Autor(zy) (2026). Consciousness as Uncommon Self-Knowledge: A Synergistic Information Framework. *arXiv preprint*.
- [4] Friston, K. (2010). The free-energy principle: a unified brain theory? *Nature Reviews Neuroscience*.
- [5] Deane, G. (2021). Consciousness in active inference: Deep self-models, other minds, and the challenge of psychedelic-induced ego-dissolution. *Neuroscience of Consciousness*.
- [6] Rosenthal, D. (2005). *Consciousness and Mind*. Oxford University Press.
- [7] Behrouz, A., Zhong, P., & Mirrokni, V. (2024). Titans: Learning to Memorize at Test Time. *arXiv:2501.00663*.
- [8] von Oswald, J., i in. (2023). Transformers learn in-context by gradient descent. *ICML*.
- [9] Premakumar, V., i in. (2026). Unexpected benefits of self-modelling in neural systems. *Philosophical Transactions of the Royal Society A*.
- [10] Autor(zy) (2026). Self-Monitoring Benefits from Structural Integration: Lessons from Metacognition in Continuous-Time Multi-Timescale Agents. *arXiv preprint*.
- [11] Autor(zy) (2026). Interoceptive machine framework: Toward interoception-inspired regulatory architectures in artificial intelligence. *arXiv preprint*.
- [12] Casali, A. G., Gosseries, O., Rosanova, M., i in. (2013). A theoretically based index of consciousness independent of sensory processing and behavior. *Science Translational Medicine*.
- [13] Cerullo, M. A. (2015). The Problem with Phi: A Critique of Integrated Information Theory. *PLOS Computational Biology*.
- [14] Autor(zy) (2021). How hot is the hot zone? Computational modelling clarifies the role of parietal and frontoparietal connectivity during anaesthetic-induced loss of consciousness. *bioRxiv / NeuroImage*.

- [15] Autor(zy). Disruption of Frontal–Parietal Communication by Ketamine, Propofol, and Sevoflurane. *Anesthesiology*.
- [16] Autor(zy) (2022). A unified model of ketamine’s dissociative and psychedelic properties. *Frontiers/PMC*.
- [17] Van de Cruys, S., Evers, K., Van der Hallen, R., Van Eylen, L., Boets, B., de-Wit, L., & Wagemans, J. (2014). Precise minds in uncertain worlds: Predictive coding in autism. *Psychological Review*, 121(4), 649–675.
- [18] Qela, B., i in. (2025). Predictive-processing deviations across autism, schizophrenia, and depression: a systematic mapping. *Journal TBD*.